

Reto Connect-4 — Agente Q-Learning Bipolar (nico)

Fundamentos de Inteligencia Artificial 2026.1 | Universidad de La Sabana | Clase: QLearningBipolarV2

Idea principal

El agente combina **Q-Learning Bipolar offline** (Hojas 11-12) con **busqueda minimax + poda alfa-beta + iterative deepening + tabla de transposicion** en linea. La Q-table aprendida sirve como funcion de evaluacion en las hojas de la busqueda. Esto es teoricamente coherente: equivale a un n-step Bellman backup online, donde la Q-table aproxima los valores y la busqueda los refina exactamente para las secuencias cortas criticas. Se distingue del MCTS de mi companero en el paradigma: yo *recuerdo* (aprendizaje offline) y *busco* (planificacion exacta); MCTS solo *simula* en linea.

Evolucion del agente

Versi on	Algoritmo	Hoja	Rol
V0	Politica aleatoria	—	Baseline / oponente de referencia
V1	Monte Carlo + eps-greedy	11	Algoritmo crudo, motivar mejoras
V2	Q-Learning Bipolar + UCB + heuristica + simetria	10, 12	Aprendizaje offline robusto
Final	V2 + minimax alfa-beta + iterative deepening + TT	10, 12 + busqueda adversarial	Agente del torneo

Curva de aprendizaje




Figura 1. Tasa de victoria contra RandomPolicy en funcion de los episodios de self-play. Eje X log. V2 alcanza >99% con 15k episodios; V1 (Monte Carlo puro) se estabiliza alrededor de 68% por la alta varianza de las estimaciones MC en estados poco visitados. La version Final (no graficada aqui) parte de la Q-table de V2 y le suma busqueda minimax: cierra el 1% residual de derrotas (amenazas dobles) al considerar explicitamente las consecuencias 4 turnos hacia adelante.

Ablacion de la heuristica de seguridad




Figura 2. Misma Q-table V2, dos politicas de inferencia: con la heuristica WIN/BLOCK activada vs desactivada. El aporte es de ~33 puntos porcentuales — el agente *aprendio* a evitar perder, pero la heuristica garantiza explicitamente no caer en las jugadas perdedoras obvias incluso en estados que el entrenamiento no visito. Es la **variable activable/desactivable** del criterio 100% de la rubrica.

Resumen de desempeno

Configuracion	Wins vs Random	Tiempo/juego	%minuto
V1 (MC, 15k ep)	68 %	<10 ms	<0.02 %
V2 con heuristica	99 %	<10 ms	<0.02 %
Final (minimax + TT, 1s/move)	100 %	~500 ms	~1 %

El profesor enfatizo *no debe ser el mas eficiente, sino el mas optimo*. Por eso el agente Final usa un presupuesto de 1s por movimiento (de los 60s disponibles): suficiente para que iterative deepening alcance profundidad >10 con TT, eliminando las derrotas por amenazas dobles que el Q-Learning puro no podia prevenir.

Cuello de botella y propuesta de mejora

Limitacion identificada empiricamente: la cobertura del Q-table decae con la profundidad del juego. Aun con 100k episodios de self-play y augmentacion por simetria, V2 encuentra estados nuevos en evaluacion (~10% de los turnos avanzados). En la version Final, el minimax compensa esto, pero los nodos hoja siguen evaluandose con $Q=0$ cuando el estado no esta en la tabla — lo que limita la calidad de la busqueda mas alla del horizonte conocido.

Mejora propuesta: reemplazar el indexado del Q-table (tablero crudo, $\sim 10^6$ estados) por un vector de *features estructurales*: numero de amenazas 3-en-linea propias y del oponente, control del centro (suma de fichas en columnas 2-4), alturas relativas. Esto reduciria el espacio efectivo a $\sim 10^3$ estados abstractos, permitiendo *generalizacion* de estados vistos a estados nuevos similares (aproximacion de funciones, Hoja 12). **Causa-efecto esperado:** la evaluacion en hojas del minimax dejaria de ser cero en estados desconocidos, lo que daria una busqueda mas informada y mejor desempeno contra rivales fuertes (no solo Random).