

Reto Connect-4 Agente Q-Learning Bipolar : Nicolas Almonacid Muñoz


Idea principal del agente

El agente utiliza Q-Learning bipolar offline mediante self-play para aprender una política de juego antes del torneo. Durante el entrenamiento, el agente juega miles de partidas contra sí mismo y almacena el valor esperado de cada acción en una Q-table indexada por estados del tablero canonicalizados por jugador. Esta canonicalización transforma el tablero de manera que las fichas propias siempre se representen como +1 y las del oponente como -1, permitiendo reutilizar el conocimiento independientemente del color asignado. La Q-table resultante contiene aproximadamente 10^6 estados visitados durante el entrenamiento. En tiempo de ejecución, el agente no realiza simulaciones ni búsquedas profundas; simplemente consulta la Q-table para seleccionar la acción con mayor valor esperado, complementando la decisión con heurísticas de seguridad para detectar victorias inmediatas o bloquear amenazas del oponente. Conceptualmente, este enfoque difiere de agentes basados en Monte Carlo Tree Search (MCTS). Mientras MCTS planifica online mediante simulaciones durante cada turno, este agente realiza el aprendizaje offline y reutiliza la experiencia acumulada previamente. En otras palabras, el agente basado en Q-Learning “recuerda” estrategias aprendidas, mientras que MCTS “simula” posibles futuros antes de actuar.

Evolución del agente


Version	Algoritmo	Rol
V0	Política aleatoria	Oponente de referencia
V1	First-Visit Monte Carlo + eps-greedy	Algoritmo crudo, motivar mejoras
V2	Q-Learning Bipolar + UCB + simetria + heurística WIN/BLOCK	Agente funcionando correctamente

Análisis 1: La curva de aprendizaje



RandomPolicy en función del número de episodios de self-play. Eje X en escala logarítmica. Cada punto promedia 300 juegos alternando colores. V2 supera el 99% con 15k episodios; V1 se estabiliza alrededor del 68% (techo del MC puro en este espacio de estados, donde la mayoría de los estados se visitan 1-2 veces)

Analisis 2: Ablacion de la heuristica (variable on/off)



Comparación entre dos políticas de inferencia utilizando la misma Q-table entrenada: una versión con heurística de seguridad activada (QLearningPolicy) y otra sin heurística (QLearningPolicyNoHeuristic). Los resultados muestran que la heurística aporta aproximadamente 33 puntos porcentuales en la tasa de victorias, representando la diferencia entre un agente que casi siempre gana y uno que solo gana cerca de dos tercios de las partidas. El principal aporte de la heurística ocurre en estados poco visitados durante el entrenamiento, donde la información almacenada en la Q-table es insuficiente o poco confiable. En estas situaciones, las reglas WIN/BLOCK funcionan como una red de seguridad táctica, permitiendo detectar victorias inmediatas o bloquear amenazas críticas del oponente. Este experimento cumple el criterio de ablación de la rúbrica, ya que compara dos configuraciones del mismo agente y demuestra empíricamente el impacto de un componente específico sobre el rendimiento final.

Hallazgos adicionales

muestran que el agente mantiene un desempeño superior al 98% tanto jugando como rojo como amarillo, aunque existe una ligera ventaja para el jugador que inicia, consistente con la teoría clásica de Connect-4 descrita por Allis (1988). En experimentos de auto-juego (V2 vs V2), el jugador rojo domina la mayoría de partidas, lo cual valida que el agente se comporta de manera coherente y competitiva con ambos colores. Respecto al parámetro de exploración de UCB, los mejores resultados se obtienen cerca del valor teórico $c = \sqrt{2} \approx 1.41$. Valores bajos producen subexploración y reducen la diversidad de estados aprendidos, mientras que valores demasiado altos generan sobreexploración y ralentizan el aprendizaje.

Conclusion

Finalmente, el análisis de cobertura de la Q-table permitió identificar el principal cuello de botella del sistema. Aunque el agente fue entrenado durante 100k episodios y utiliza simetría izquierda-derecha para reducir el espacio de estados, durante evaluación siguen apareciendo miles de estados nuevos que no existen en la Q-table. En estos casos, el agente depende del fallback heurístico (heurística + preferencia por columnas centrales). Las pocas derrotas residuales contra RandomPolicy ocurren principalmente por amenazas dobles simultáneas que no pueden bloquearse con una única jugada. Como mejora futura, se propone reemplazar la representación cruda del tablero por una abstracción basada en features estructurales, tales como número de amenazas propias y rivales, control del centro y alturas relativas de columnas. Esto permitiría reducir drásticamente el espacio efectivo de estados y mejorar la capacidad de generalización del agente hacia posiciones no vistas previamente, siguiendo la idea de aproximación de funciones para MDPs grandes.

